

Laporan Tugas Besar

Deteksi Penyakit Tanaman Menggunakan Classical Preprocessing dan EfficientNetB0

Nama : M. Raditya Faturrahman

NIM : 1304221050

Mata Kuliah : Pemrosesan Citra Digital (CII4F3)

Abstrak

Laporan ini memaparkan implementasi sistem deteksi penyakit tanaman menggunakan dataset PlantVillage yang terdiri dari 54.305 citra daun dari 38 kelas. Pipeline preprocessing klasik diterapkan sebelum training: Gaussian blur, Median blur, CLAHE pada ruang warna LAB, contrast stretching, dan HSV masking dengan mekanisme fallback untuk menangani daun yang menguning atau terinfeksi berat. Model yang digunakan adalah EfficientNetB0 dengan strategi dua fase: fase feature extraction (base frozen) dilanjutkan fase fine-tuning penuh. Hasil evaluasi pada data validasi menunjukkan akurasi 89,22% dan F1-score makro 83,28%.

1. Pendahuluan

Penyakit tanaman menjadi salah satu faktor utama penurunan hasil panen di berbagai belahan dunia. Identifikasi penyakit secara manual membutuhkan tenaga ahli dan waktu yang tidak sedikit, sehingga pendekatan berbasis citra digital mulai banyak dikembangkan sebagai alternatif yang lebih efisien. Dengan berkembangnya teknik deep learning, khususnya convolutional neural network (CNN), klasifikasi penyakit tanaman melalui foto daun menjadi semakin memungkinkan dengan akurasi yang kompetitif.

Tugas besar ini bertujuan membangun pipeline lengkap yang menggabungkan teknik preprocessing citra klasik dengan transfer learning berbasis EfficientNetB0. Preprocessing klasik digunakan untuk meningkatkan kualitas visual citra sebelum diumpankan ke model, sementara EfficientNetB0 dimanfaatkan karena efisiensinya dalam hal parameter dibandingkan arsitektur CNN modern lainnya. Dataset yang digunakan adalah PlantVillage, salah satu dataset publik terbesar untuk klasifikasi penyakit daun tanaman.

2. Dataset

Dataset PlantVillage (versi warna) digunakan dalam eksperimen ini. Dataset berisi 54.305 citra daun dari berbagai jenis tanaman yang diambil dengan latar belakang seragam. Total terdapat 38 kelas yang merepresentasikan kondisi sehat maupun berbagai jenis penyakit pada 14 spesies tanaman, antara lain apel, blueberry, ceri, jagung, anggur, jeruk, persik, paprika, kentang, raspberry, kedelai, labu siam, stroberi, dan tomat.

Dataset dibagi menjadi 80% data latih dan 20% data validasi secara stratified, menghasilkan 43.456 citra untuk training dan 10.849 citra untuk validasi. Distribusi kelas tidak seimbang; kelas Orange___Haunglongbing memiliki 5.507 sampel, sedangkan Potato___healthy hanya 152 sampel. Karena itu, class weighting diterapkan selama training untuk mengurangi bias prediksi ke kelas mayoritas.

Tabel 1. Ringkasan Dataset PlantVillage

Komponen	Jumlah	Keterangan
Total citra	54.305	38 kelas
Training set	43.456	80%
Validation set	10.849	20%
Ukuran citra input	224×224	piksel, RGB
Spesies tanaman	14 spesies	sehat + sakit

3. Pipeline Preprocessing Klasik

Sebelum citra diumpankan ke model, setiap gambar melewati lima tahap preprocessing. Tahap pertama adalah Gaussian blur dengan kernel 5×5 untuk menekan noise frekuensi tinggi. Tahap kedua adalah Median blur dengan kernel 3×3 yang efektif menghilangkan noise impuls tanpa mengaburkan tepi objek secara berlebihan.

Tahap ketiga adalah CLAHE (Contrast Limited Adaptive Histogram Equalization) yang diterapkan pada channel L dari ruang warna LAB. Pendekatan ini meningkatkan kontras secara lokal tanpa mempengaruhi informasi warna, yang penting untuk membedakan bercak penyakit dari warna daun normal. Tahap keempat adalah contrast stretching linier yang memetakan rentang nilai piksel ke $[0, 255]$ secara adaptif per citra.

Tahap kelima adalah HSV masking untuk mengisolasi area daun dari latar belakang. Range masking diperlebar ke $[20, 20, 20]$ sampai $[100, 255, 255]$ di ruang HSV untuk mencakup warna

daun yang lebih beragam termasuk daun kuning atau kecoklatan akibat penyakit. Mekanisme fallback ditambahkan: jika rata-rata intensitas hasil masking di bawah 8.0, gambar dikembalikan tanpa masking untuk menghindari input all-zero yang menyebabkan NaN loss pada fungsi cross-entropy.

Seluruh preprocessing dijalankan sekali di awal dan hasilnya disimpan ke disk (/kaggle/working/plantvillage_processed). Data generator kemudian membaca dari cache tersebut dan hanya menerapkan normalisasi (rescale 1/255) serta augmentasi standar saat training, sehingga tidak ada operasi berat yang diulang per batch.

4. Arsitektur dan Strategi Training

4.1. Arsitektur EfficientNetB0

Model yang digunakan adalah EfficientNetB0 dengan bobot pralatih dari ImageNet. EfficientNetB0 dipilih karena memberikan keseimbangan yang baik antara akurasi dan efisiensi komputasi. Arsitektur ini 8,4 kali lebih kecil dan 6,1 kali lebih cepat dari ResNet-50 dengan akurasi yang lebih tinggi pada ImageNet. Model terdiri dari 4.387.273 parameter total, dengan 337.702 parameter yang dapat dilatih pada fase pertama (kepala klasifikasi dan lapisan tambahan).

Di atas base model EfficientNetB0, ditambahkan Global Average Pooling 2D untuk meratakan fitur spasial, dilanjutkan Dense 256 unit dengan aktivasi ReLU, Dropout 0,4 untuk regularisasi, dan Dense output 38 unit dengan aktivasi softmax sesuai jumlah kelas.

4.2. Strategi Training Dua Fase

Training dilakukan dalam dua fase. Fase pertama (feature extraction) membekukan seluruh base model EfficientNetB0 dan hanya melatih lapisan kepala selama maksimal 5 epoch dengan learning rate 1×10^{-4} . Fase ini bertujuan menyesuaikan bobot kepala klasifikasi sebelum fine-tuning dilakukan, agar gradient dari lapisan acak tidak merusak bobot pralatih yang sudah baik.

Fase kedua (fine-tuning) membuka seluruh lapisan base model dan melanjutkan training dengan learning rate yang lebih kecil, 1×10^{-5} , selama maksimal 10 epoch. Learning rate yang kecil penting agar fitur yang sudah dipelajari dari ImageNet tidak terhapus secara tiba-tiba. Callback yang digunakan meliputi EarlyStopping (patience=3), ReduceLROnPlateau (faktor 0,5, patience=2), dan ModelCheckpoint yang menyimpan bobot terbaik berdasarkan val_accuracy.

Tabel 2. Konfigurasi Hyperparameter

Parameter	Fase 1	Fase 2
Learning rate	1×10^{-4}	1×10^{-5}
Epoch maksimal	5	10
Batch size	32	32
Base model	Frozen	Trainable
Optimizer	Adam	Adam
Loss function	Categorical CE	Categorical CE

5. Hasil dan Analisis

5.1. Performa Training

Fase pertama menunjukkan akurasi validasi yang stagnan di sekitar 10% (setara prediksi acak untuk 38 kelas), yang memang diharapkan karena base model masih frozen dan kepala klasifikasi baru diinisialisasi secara acak. EarlyStopping memilih epoch ke-2 sebagai best checkpoint dengan val_accuracy 10,16%.

Begitu fine-tuning dimulai pada fase kedua, akurasi meningkat drastis. Pada epoch pertama fine-tuning, val_accuracy langsung melonjak ke 52,51%, dan terus meningkat hingga mencapai 89,22% di epoch ke-10. Seluruh 10 epoch berjalan tanpa memicu EarlyStopping, yang menunjukkan model masih dalam tren peningkatan. Loss validasi turun konsisten dari 2,27 di awal fine-tuning menjadi 0,55 di epoch terakhir.

Tabel 3. Ringkasan Performa per Fase Training

Fase	Epoch Terbaik	Train Acc	Val Acc	Val Loss
Fase 1 (Frozen)	2	9,95%	10,16%	3,6236
Fase 2 (Fine-tune)	10	87,81%	89,22%	0,5460

5.2. Evaluasi Akhir

Model dievaluasi pada 10.849 citra validasi. Akurasi keseluruhan mencapai 89,22% dengan F1-score makro 83,28% dan F1-score tertimbang 85,70%. Sebagian besar kelas menunjukkan performa yang sangat baik, namun terdapat beberapa kelas yang menjadi tantangan tersendiri.

Tabel 4. Hasil Evaluasi Akhir

Metrik	Nilai
Akurasi	89,22%
F1-score Makro	83,28%
F1-score Tertimbang (Weighted)	85,70%
Jumlah kelas dievaluasi	38 kelas
Total sampel validasi	10.849 citra

5.3. Analisis Per Kelas

Dari 38 kelas yang dievaluasi, 21 kelas mencapai F1-score di atas 0,93. Performa terbaik diraih oleh Apple___Black_rot dan Raspberry___healthy dengan F1 = 1,00, diikuti berbagai kelas lain seperti Grape___Black_rot (0,99), Orange___Haunglongbing (0,99), Cherry___healthy (0,99), dan Soybean___healthy (0,98). Kelas-kelas ini umumnya memiliki ciri visual yang khas dan kontras sehingga mudah dipisahkan oleh model.

Sementara itu, terdapat empat kelas dengan F1-score 0,00, yaitu Corn___Cercospora_leaf_spot, Corn___Northern_Leaf_Blight, Corn___healthy, dan Tomato___Late_blight. Penyebab utamanya dapat dilihat dari classification report: kelas Corn___Common_rust memiliki recall 1,00 dengan precision hanya 0,42, yang mengindikasikan model mengklasifikasikan hampir semua citra jagung sebagai Common_rust. Ini menunjukkan bahwa model belum mampu membedakan tekstur antar penyakit jagung yang secara visual memiliki kemiripan tinggi, terutama setelah HSV masking mengubah warna karakteristik tiap penyakit.

Kelas Tomato___Late_blight (381 sampel) juga mendapat F1 = 0,00 meskipun memiliki cukup banyak sampel. Ini kemungkinan disebabkan oleh kesamaan visual dengan kelas Tomato___Early_blight dan Tomato___Septoria_leaf_spot, yang keduanya juga menunjukkan bercak coklat pada daun tomat. Dengan epoch fine-tuning yang lebih banyak atau augmentasi yang lebih agresif, kelas-kelas ini berpotensi menunjukkan peningkatan.

Tabel 5. Kelas dengan Performa Terbaik dan Terburuk

Kelas	Precision	Recall	F1
Apple___Black_rot	1,00	0,99	1,00
Raspberry___healthy	1,00	1,00	1,00
Orange___Haunglongbing	0,97	1,00	0,99
Grape___Black_rot	0,99	0,99	0,99

Tomato___Yellow_Leaf_Curl_Virus	0,98	1,00	0,99
Corn___Cercospora_leaf_spot	0,00	0,00	0,00
Corn___Northern_Leaf_Blight	0,00	0,00	0,00
Corn___healthy	0,00	0,00	0,00
Tomato___Late_blight	0,00	0,00	0,00

6. Diskusi

Secara keseluruhan, akurasi 89,22% yang dicapai cukup kompetitif untuk klasifikasi 38 kelas pada dataset PlantVillage. Penelitian sebelumnya yang menggunakan VGG16 atau ResNet tanpa preprocessing klasik umumnya melaporkan akurasi di rentang 85-96% tergantung metode augmentasi dan jumlah epoch. EfficientNetB0 dalam eksperimen ini menunjukkan kemampuan generalisasi yang baik meskipun pipeline preprocessing mengubah distribusi warna dari gambar asli.

Satu hal yang perlu dicermati adalah dampak HSV masking terhadap kelas tanaman tertentu. Jagung dan tomat memiliki banyak subkelas dengan penampakan visual yang mirip, dan masking yang mengubah warna bercak penyakit bisa menghilangkan fitur diskriminatif antar kelas tersebut. Ke depan, pendekatan yang lebih selektif, misalnya hanya menerapkan masking pada tanaman tertentu atau menggunakan segmentasi berbasis model seperti U-Net, dapat memberikan hasil yang lebih baik.

Pada sisi positifnya, strategi cache preprocessing terbukti efektif secara komputasi: seluruh preprocessing 54.305 gambar diselesaikan dalam sekali jalan, dan training kemudian berjalan dengan kecepatan normal tanpa overhead per-batch. Class weighting juga membantu mencegah bias ekstrem ke kelas mayoritas seperti Orange___Haunglongbing (5.507 sampel) yang mendominasi jika tidak ditangani.

7. Kesimpulan

Sistem deteksi penyakit tanaman berhasil diimplementasikan menggunakan pipeline yang menggabungkan preprocessing klasik (Gaussian blur, Median blur, CLAHE, contrast stretching, HSV masking) dengan transfer learning EfficientNetB0 pada dataset PlantVillage 38 kelas. Hasil evaluasi menunjukkan akurasi 89,22% dan F1-score makro 83,28% pada data validasi.

Dari 38 kelas, 21 kelas mencapai F1 di atas 0,93, sementara kelas-kelas jagung dan Tomato___Late_blight masih menjadi tantangan karena kemiripan visual antar subkelas. Perbaikan yang dapat dilakukan ke depan antara lain penambahan epoch, penyesuaian rentang HSV masking per jenis tanaman, dan eksplorasi arsitektur yang lebih besar seperti EfficientNetB3 atau Vision Transformer untuk fitur yang lebih kaya.

Daftar Pustaka

- Hughes, D. P., & Salathe, M. (2015). An open access repository of images on plant health to enable the development of mobile disease diagnostics. arXiv:1511.08060.
- Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. Proceedings of the 36th ICML, 97, 6105-6114.
- Reza, A. M. (2004). Realization of the contrast limited adaptive histogram equalization (CLAHE) for real-time image enhancement. Journal of VLSI Signal Processing Systems, 38(1), 35-44.
- Mohanty, S. P., Hughes, D. P., & Salathe, M. (2016). Using deep learning for image-based plant disease detection. Frontiers in Plant Science, 7, 1419.
- Prajapati, H. B., Shah, J. P., & Dabhi, V. K. (2017). Detection and classification of rice plant diseases. Intelligent Decision Technologies, 11(3), 357-373.